

A Matemática das Redes Neurais Artificiais: Uma Visão Geométrica

Davi Picanço dos Reis¹, Helaine Cristina Moraes Furtado²

¹Universidade Federal do Oeste do Pará, davipicancodosreis@gmail.com

²Universidade Federal do Oeste do Pará, helaine.furtado@ufopa.edu.br

Resumo. As Redes Neurais Artificiais tornaram-se essenciais para a ciência e tecnologia nas últimas décadas, ganhando grande popularidade. Contudo, seu funcionamento técnico costuma ser restrito a especialistas, o que gera uma percepção “mágica” no público geral. Nesse contexto, este trabalho tem como objetivo apresentar a fundamentação matemática das Redes Neurais Artificiais, com ênfase em sua interpretação geométrica, visando promover uma compreensão mais intuitiva e introdutória sobre o tema. Para isso, são discutidos conceitos de Álgebra Linear relacionados ao perceptron, ao produto escalar e à interpretação de hiperplanos no espaço de dados.

Palavras-chave. Redes Neurais Artificiais; Machine Learning; Inteligência Artificial; Álgebra Linear.

1. DESENVOLVIMENTO

1.1. Formulação Matemática

Uma Rede Neural Artificial (RNA) é um modelo computacional inspirado pelo funcionamento do cérebro humano [1]. É formada por vários neurônios conectados que transferem informação entre si [2]. E o seu principal objetivo é desenvolver a capacidade de aprender com a experiência, ou seja, aprender diretamente a partir dos dados [3].

O Perceptron é o modelo mais simples de neurônio, ele é a unidade computacional básica de uma RNA [4]. Ele é responsável por receber dados, na forma de vetor, fazer o processamento e retornar um valor real [5]. Assim, o seu processamento pode ser representado pela equação [6]:

$$y(\mathbf{x}) = \varphi(\mathbf{w}^T \cdot \mathbf{x} + b) \quad (1)$$

O vetor $\mathbf{x}$ é o vetor com os dados de entrada, $\mathbf{w}$ é o vetor de pesos, ou parâmetros, que também tem dimensão n , b é o *bias*, φ é chamada de função de ativação e $y(\mathbf{x})$ é o resultado do processamento ou a ativação do neurônio, dada uma entrada de dados.

1.2. Interpretação Geométrica

Agora, utilizando uma intuição geométrica, consideremos as seguintes afirmações como verdadeiras:

- O produto escalar fornece uma interpretação geométrica relacionada à similaridade angular entre vetores [7];
- Dados podem ser vistos como pontos em um espaço [8];
- Um vetor e um ponto determinam um hiperplano no espaço [9].

Por enquanto, tomemos a função de ativação φ como a função identidade, de modo que não afete o resultado do processamento. Assim, considerando uma RNA já treinada, temos

um vetor w já definido. Levando em consideração os pontos podemos ter até 2 níveis de uma interpretação geométrica.

Primeiramente consideremos que o vetor de pesos w já treinado aponta para certa posição nesse espaço de dados, e quando fazemos o produto escalar do vetor de entradas x com ele, o que se está medindo é a similaridade entre eles, ou seja, se eles estão próximos da mesma posição. Portanto, o neurônio pode avaliar, no espaço de dados, o grau de compatibilidade entre os dados de entrada e o padrão aprendido durante o treinamento.

A segunda abordagem leva em consideração uma equação do plano: $p(x,y,z) = ax + bx + cz + d$. Podemos notar, ainda desconsiderando a função de ativação, que a equação (1) também é uma equação de plano, mas em um espaço multidimensional, ou seja, um hiperplano.

$$y(x_1, x_2, \dots, x_n) = w_1x_1 + w_2x_2 + \dots + w_nx_n + b \quad (2)$$

Nesse caso os $w_1, w_2, \dots, w_n, b$ seriam os coeficientes desse hiperplano. Ou seja, um neurônio já treinado determina um hiperplano no espaço de dados, e isso somado ao fato que os dados são pontos nesse espaço podemos dizer que o hiperplano separa os dados que tem certa semelhança dos que não tem.

Entretanto, a classe de problemas linearmente separáveis é bastante limitada quando comparada aos problemas não lineares encontrados em aplicações reais. Nesse contexto, a função de ativação introduz não linearidades no processamento da rede neural, ampliando sua capacidade de representação. De forma geométrica, pode-se interpretar que a função de ativação transforma o espaço de representação dos dados, permitindo que padrões originalmente não separáveis linearmente passem a ser distinguidos por hiperplanos.

Assim, temos a interpretação geométrica completa do processamento do neurônio, um neurônio é responsável por separar o espaço de dados em dois por meio de uma superfície, de modo a categorizar os dados que contribuem ou não para o padrão esperado pelo neurônio.

Podemos ainda expandir essa interpretação para uma RNA com mais neurônios e camadas. Nesse caso cada neurônio fica responsável por segmentar os dados de uma forma diferente, e criando no espaço de dados vários subespaços que podem ser categorizados de acordo com o esperado pela rede.

2. CONSIDERAÇÕES FINAIS

A interpretação geométrica apresentada permite compreender as Redes Neurais Artificiais para além de uma visão puramente computacional, relacionando conceitos de Álgebra Linear, hiperplanos e separação de dados no espaço vetorial. Dessa forma, o trabalho contribui para uma compreensão mais intuitiva do funcionamento das RNAs, evidenciando como ferramentas matemáticas podem auxiliar na interpretação de modelos amplamente utilizados em Inteligência Artificial.