

# A Matemática das Redes Neurais Artificiais: Uma Visão Geométrica

Davi Picanço dos Reis<sup>1</sup>, Helaine Cristina Moraes Furtado<sup>2</sup>

<sup>1</sup>Universidade Federal do Oeste do Pará, [davipicancodosreis@gmail.com](mailto:davipicancodosreis@gmail.com)

<sup>2</sup>Universidade Federal do Oeste do Pará, [helaine.furtado@ufopa.edu.br](mailto:helaine.furtado@ufopa.edu.br)

**Resumo.** As Redes Neurais Artificiais tornaram-se essenciais para a ciência e tecnologia nas últimas décadas, ganhando grande popularidade. Contudo, seu funcionamento técnico costuma ser restrito a especialistas, o que gera uma percepção “mágica” no público geral. Nesse contexto, este trabalho tem como objetivo apresentar a fundamentação matemática das Redes Neurais Artificiais, com ênfase em sua interpretação geométrica, visando promover uma compreensão mais intuitiva sobre o tema. Para isso, são discutidos conceitos de Álgebra Linear relacionados ao Perceptron, ao produto escalar e à interpretação de hiperplanos no espaço de dados.

**Palavras-chave.** Redes Neurais Artificiais; Machine Learning; Inteligência Artificial; Álgebra Linear.

## 1. DESENVOLVIMENTO

### 1.1. Formulação Matemática

Uma Rede Neural Artificial (RNA) é uma máquina, um modelo computacional, projetada para modelar a maneira como o cérebro realiza uma tarefa particular (Haykin, 2001, p. 28). Ela é composta por um grande número de neurônios conectados, que transferem sinais, informação, entre si (Fausett, 1994, p. 3). E o seu principal objetivo é desenvolver a capacidade de aprender com a experiência, ou seja, aprender diretamente a partir dos dados (Haykin, 2001, p. 28).

O Perceptron é a forma mais simples de uma rede neural (Haykin, 2001, p. 143). Ele é responsável por receber dados, na forma de vetor, fazer o processamento e retornar um valor (Fausett, 1994, p. 3). O seu processamento pode ser representado pela equação (Haykin, 2001, p. 37, adaptado):

$$y(\mathbf{x}) = \varphi(\mathbf{w}^T \cdot \mathbf{x} + b) \quad (1)$$

O vetor  $\mathbf{x}$  é o vetor com os dados de entrada,  $\mathbf{w}$  é o vetor de pesos, ou parâmetros, que também tem dimensão  $n$ ,  $b$  é o *bias*,  $\varphi$  é chamada de função de ativação e  $y(\mathbf{x})$  é o resultado do processamento ou a ativação do neurônio, dada uma entrada de dados (Haykin, 2001, p. 37-38).

### 1.2. Interpretação Geométrica

Agora, para um melhor entendimento, utilizando uma intuição geométrica, consideremos as seguintes afirmações abaixo (Haykin, 2001, p. 51-52):

- O produto escalar fornece a similaridade angular entre vetores;
- Dados podem ser vistos como pontos em um espaço.

Por enquanto, tomemos a função de ativação  $\varphi$  como a função identidade, de modo que não afete o resultado do processamento. Assim, considerando uma RNA já treinada, temos um vetor  $\mathbf{w}$  já definido. Levando em consideração os pontos anteriores podemos ter até 2 níveis de uma interpretação geométrica.

Primeiro, consideremos que o vetor de pesos  $w$  já treinado aponta para certa posição nesse espaço de dados, e quando fazemos o produto escalar do vetor de entradas  $x$  com ele, o que se está medindo é a similaridade entre eles, ou seja, se eles estão próximos da mesma região no espaço de dados. Portanto, o neurônio pode avaliar, no espaço de dados, o grau de compatibilidade entre os dados de entrada e o padrão aprendido durante o treinamento.

Segundo, levando em consideração uma equação do plano. Podemos notar, ainda desconsiderando a função de ativação, que a equação (1) se assemelha a uma equação de um hiperplano, em um espaço multidimensional. Assim, um neurônio já treinado determina um hiperplano no espaço de dados, uma fronteira de decisão, criando duas regiões no espaço, os dados que são compatíveis com o padrão esperado e os que não são (Haykin, 2001, p. 163).

Entretanto, a classe de problemas linearmente separáveis é bastante limitada quando comparada aos problemas não lineares encontrados em aplicações reais. Nesse contexto, a função de ativação introduz não linearidades no processamento da rede neural, ampliando sua capacidade de representação. De forma geométrica, pode-se interpretar que a função de ativação transforma o espaço de representação dos dados, permitindo que padrões originalmente não separáveis linearmente passem a ser distinguidos por hiperplanos (Olah, 2014).

Assim, temos a interpretação geométrica completa do processamento do neurônio, um neurônio é responsável por separar o espaço de dados em dois por meio de uma superfície, de modo a categorizar os dados que contribuem ou não para o padrão esperado pelo neurônio.

Podemos ainda expandir essa interpretação para uma RNA com mais neurônios e camadas. Nesse caso cada neurônio fica responsável por segmentar os dados de uma forma diferente, e criando no espaço de dados vários subespaços que podem ser categorizados de acordo com o esperado pela rede (Haykin, 2001, p. 29).

## 2. CONSIDERAÇÕES FINAIS

A interpretação geométrica apresentada permite compreender as Redes Neurais Artificiais para além de uma visão puramente computacional, relacionando conceitos de Álgebra Linear, hiperplanos e separação de dados no espaço vetorial. Dessa forma, o trabalho contribui para uma compreensão mais intuitiva do funcionamento das RNAs, evidenciando como ferramentas matemáticas podem auxiliar na interpretação de modelos amplamente utilizados em Inteligência Artificial.

## REFERÊNCIAS

Laurene V. Fausett. **Fundamentals of Neural Networks: Architectures, Algorithms, and Applications**. Upper Saddle River, NJ: Prentice Hall, 1994.

Simon Haykin. **Redes Neurais: Princípios e Prática**. 2. ed. Porto Alegre: Bookman, 2001. Original em inglês: *Neural Networks: A Comprehensive Foundation*.

Christopher Olah. **Neural Networks, Manifolds, and Topology**. 6 mar. 2014. Disponível em: <https://colah.github.io/posts/2014-03-NN-Manifolds-Topology/>. Acesso em: 8 maio 2026.