

A Matemática das Redes Neurais Artificiais: Uma Visão Geométrica

Davi Picanço dos Reis¹, Helaine Cristina Moraes Furtado²

¹Universidade Federal do Oeste do Pará, davipicancodosreis@gmail.com

²Universidade Federal do Oeste do Pará, helaine.furtado@ufopa.edu.br

Resumo. As Redes Neurais Artificiais tornaram-se essenciais para a ciência e tecnologia nas últimas décadas, ganhando grande popularidade. Contudo, seu funcionamento técnico costuma ser restrito a especialistas, o que gera uma percepção "mágica" no público geral. Nesse contexto, este trabalho apresenta os fundamentos matemáticos e a interpretação geométrica dessas redes, visando promover uma compreensão intuitiva e introdutória sobre o tema.

Palavras-chave. Redes Neurais Artificiais; Machine Learning; Inteligência Artificial; Álgebra Linear.

1. DISCUSSÃO

Uma Rede Neural Artificial (RNA) é um modelo computacional inspirado pelo funcionamento do cérebro humano. É formada por vários neurônios conectados que transferem informação entre si. E o seu principal objetivo é desenvolver a capacidade de aprender com a experiência, ou seja, aprender diretamente dos dados.

O Perceptron é o modelo mais simples de neurônio, ele é a unidade computacional básica de uma RNA. Ele é responsável por receber dados, na forma de vetor, fazer o processamento e retornar um valor real. Assim, o seu processamento pode ser representado pela equação:

$$y(\mathbf{x}) = \varphi(\mathbf{w}^T \cdot \mathbf{x} + b) \quad (1)$$

O vetor $\mathbf{x}$ é o vetor com os dados de entrada, $\mathbf{w}$ é o vetor de pesos, ou parâmetros, que também tem dimensão n , b é o *bias*, φ é chamada de função de ativação e $y(\mathbf{x})$ é o resultado do processamento ou a ativação do neurônio, dada uma entrada de dados.

Agora, utilizando uma intuição geométrica, consideremos as seguintes afirmações como verdadeiras:

- O produto escalar entre dois vetores mede a "similaridade" entre dois vetores;
- Dados podem ser vistos como pontos em um espaço;
- Um vetor e um ponto determinam um hiperplano no espaço.

Por enquanto, tomemos a função de ativação φ como a função identidade, de modo que não afete o resultado do processamento. Assim, considerando uma RNA já treinada, temos um vetor $\mathbf{w}$ já definido. Levando em consideração os pontos podemos ter até 2 níveis de uma interpretação geométrica.

Primeiramente consideremos que o vetor de pesos $\mathbf{w}$ já treinado aponta para certa posição nesse espaço de dados, e quando fazemos o produto escalar do vetor de entradas $\mathbf{x}$ com ele o que estamos medindo é a similaridade entre eles, ou seja, de forma mais intuitiva, se eles estão próximos da mesma posição. Portanto, podemos dizer que um neurônio pode verificar, nessa representação de dados no espaço, se os dados de entrada estão próximos ao padrão esperado pelo neurônio.

A segunda abordagem leva em consideração uma equação do plano: $p(x,y,z) = ax + bx + cx + d$. Podemos notar, ainda desconsiderando a função de ativação, que a equação (1) também é uma equação de plano, mas em um espaço multidimensional, ou seja, um hiperplano.

$$y(x_1, x_2, \dots, x_n) = w_1x_1 + w_2x_2 + \dots + w_nx_n + b \quad (2)$$

Nesse caso os $w_1, w_2, \dots, w_n, b$ seriam os coeficientes desse hiperplano. Ou seja, um neurônio já treinado determina um hiperplano no espaço de dados, e isso somado ao fato que os dados são pontos nesse espaço podemos dizer que o hiperplano separa os dados que tem certa semelhança dos que não tem.

Entretanto, a gama de problemas lineares, que podem ser separados com uma reta, são muito menores que problemas não lineares. Assim, a função proporciona uma forma de torna o processamento menor linear. De forma intuitiva, o que a função de ativação faz é transformar, dobrar, o espaço de modo que os dados se tornem linearmente separáveis, que podem ser separados por uma linha reta.

Assim, temos a interpretação geométrica completa do processamento do neurônio, um neurônio é responsável por separar o espaço de dados em dois por meio de uma superfície, de modo a categorizar os dados que contribuem ou não para o padrão esperado pelo neurônio.

Podemos ainda estender essa interpretação para uma RNA com mais neurônios e camadas. Nesse caso cada neurônio fica responsável por segmentar os dados de uma forma diferente, e criando no espaço de dados vários subespaços que podem ser categorizados de acordo com o esperado pela rede.