

A Matemática das Redes Neurais Artificiais: Uma Visão Geométrica

Davi Picanço dos Reis¹, Helaine Cristina Moraes Furtado²

¹Universidade Federal do Oeste do Pará, davipicancodosreis@gmail.com

²Universidade Federal do Oeste do Pará, helaine.furtado@ufopa.edu.br

Resumo. As Redes Neurais Artificiais tornaram-se essenciais para a ciência e tecnologia nas últimas décadas, ganhando grande popularidade. Contudo, seu funcionamento técnico costuma ser restrito a especialistas, o que gera uma percepção "mágica" no público geral. Nesse contexto, este trabalho apresenta os fundamentos matemáticos e a interpretação geométrica dessas redes, visando promover uma compreensão intuitiva e introdutória sobre o tema.

Palavras-chave. Redes Neurais Artificiais; Machine Learning; Inteligência Artificial; Álgebra Linear.

1. INTRODUÇÃO

Uma Rede Neural Artificial (RNA) é um modelo computacional inspirado pelo funcionamento do cérebro humano. É formada por vários neurônios conectados que transferem informação entre si. E o seu principal objetivo é desenvolver a capacidade de aprender com a experiência, ou seja, aprender diretamente dos dados.

2. FORMULAÇÃO MATEMÁTICA

2.1. A Estrutura do Neurônio

O Perceptron é o modelo mais simples de neurônio, ele é a unidade computacional básica de uma RNA. O neurônio é responsável por receber dados, na forma de vetor, fazer o processamento e retornar um valor real. Definimos então o neurônio como uma função $y : \mathbb{V}^n \rightarrow \mathbb{R}$, onde n é um natural não nulo e é dada por

$$y(\mathbf{x}) = \varphi(\mathbf{w}^T \cdot \mathbf{x} + b) \quad (1)$$

O vetor $\mathbf{x}$ é o vetor com os dados de entrada, $\mathbf{w}$ é o vetor de pesos, ou parâmetros, que também tem dimensão n , b é o *bias*, φ é chamada de função de ativação e $y(\mathbf{x})$ é o resultado do processamento ou a ativação do neurônio, dada uma entrada de dados.

2.2. Generalização para Várias Camadas

Para lidar com o processamento em várias camadas definimos, para uma rede com n camadas:

$$Z_k = W_k \cdot A_{k-1} + B_k \text{ com } \begin{cases} A_0 = \mathbf{x} \\ A_k = \varphi(Z_k) \end{cases} \quad (2)$$

Nesse caso W_k é a matriz de pesos relacionando cada neurônio da camada anterior à camada atual, A_k é o vetor contendo o resultado da ativação de cada neurônio da camada k e B_k é o vetor com os *biases* de cada neurônio dessa mesma camada. Nesse caso, o resultado y da rede é dado pelo vetor A_n (a última camada).

2.3. Treinando uma Rede Neural Artificial

O processo de treinamento de uma RNA consiste basicamente em 3 etapas.

Na primeira etapa definimos uma função J que mede o quanto a rede erra nas suas previsões, por exemplo, podemos utilizar o erro quadrático médio:

$$J = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \quad (3)$$

Dada a função de erro podemos identificar, por meio do gradiente de J , os ajustes necessários para minimizar o erro. Assim, os novos pesos podem ser calculados pela seguinte expressão:

$$W_k^* = W_k - \eta \frac{\partial J}{\partial W_k}, \eta \in \mathbb{R}^+ \quad (4)$$

E por fim, para calcular os ajustes necessário para os parâmetros W_k , a derivada parcial de J em relação ao peso W_k , utilizamos a regra da cadeia:

$$\frac{\partial J}{\partial W_k} = \frac{\partial J}{\partial A_k} \frac{\partial A_k}{\partial Z_k} \frac{\partial Z_k}{\partial W_k} \quad (5)$$

3. INTERPRETAÇÃO GEOMÉTRICA

4. CONCLUSÃO